

Clasificación de Tweets de desastre mediante modelos de secuencia

Luis David Martínez Galindo, *Estudiante, Ingeniería de Sistemas, Universidad de Antioquia*

I. CONTEXTO DE APLICACIÓN

Durante situaciones de emergencia, desastres naturales o crisis humanitarias, las redes sociales (especialmente **Twitter / X**) se convierten en canales de comunicación críticos de primera mano. Los usuarios afectados, testigos y cuerpos de rescate publican información en tiempo real sobre la evolución de los hechos, solicitudes de auxilio o estado de la infraestructura. Para las agencias de gestión de emergencias (como la Cruz Roja o Defensa Civil), monitorear manualmente este flujo masivo de publicaciones es inviable. El desafío radica en que la plataforma contiene una enorme cantidad de ruido: los usuarios suelen usar palabras asociadas a desastres de forma metafórica (por ejemplo, *"ese concierto fue una bomba"* o *"me está lloviendo el trabajo"*). La automatización mediante Procesamiento de Lenguaje Natural (NLP) permite filtrar instantáneamente las publicaciones, aislando aquellas que reportan emergencias reales. Esto optimiza la asignación de recursos de rescate, acelera los tiempos de respuesta y mejora la toma de decisiones en situaciones donde cada minuto cuenta.

II. OBJETIVO DE MACHINE LEARNING

El objetivo técnico es construir y entrenar un modelo de aprendizaje profundo basado en **Modelos de Secuencia** (Redes Neuronales Recurrentes utilizando capas **LSTM** o **GRU**) capaz de procesar el texto y entender el contexto para distinguir el uso literal del metafórico en palabras clave de emergencia.

- **Variable a predecir (Y):** La clasificación del tuit como una variable categórica binaria: **1** si el tuit describe un desastre real (terremoto, inundación, accidente, etc.) y **0** si el tuit es una falsa alarma, uso metafórico o texto irrelevante.
- **Información de entrada (X):** Una secuencia de texto plano de longitud variable (el cuerpo del tuit), complementada opcionalmente por metadatos de texto como palabras clave (*keywords*) y ubicación (*location*), que pasará por un proceso de tokenización, normalización y capas de *embedding*.

III. DATASET: NATURAL LANGUAGE PROCESSING WITH DISASTER TWEETS

Para el desarrollo de este proyecto se utilizará el conjunto de datos oficial de la competencia de Kaggle [1] para principiantes en NLP.

- **Tipo de datos:** Datos estructurados en formato tabular (CSV). Contiene columnas numéricas (id), columnas de texto con alta presencia de valores nulos (keyword y location) y la columna principal de texto libre (text).
- **Tamaño del dataset:**

- **Número de registros:** El dataset contiene un total de 10,876 tuits, divididos oficialmente por Kaggle en un conjunto de entrenamiento (train.csv) con 7,613 registros y un conjunto de prueba (test.csv) con 3,263 registros.
- **Tamaño en disco:** Aproximadamente 1.4 MB combinando ambos archivos CSV. Su tamaño compacto lo hace ideal para su ejecución rápida, experimentación ágil y almacenamiento eficiente en los entornos de Google Colab del curso.
- **Distribución de las clases:** El dataset de entrenamiento presenta un ligero desbalance, pero es lo suficientemente robusto para entrenar sin técnicas complejas de remuestreo:
 - Clase 0 (No es desastre): ~57% (4,342 tuits)
 - Clase 1 (Desastre real): ~43% (3,271 tuits)

IV. MÉTRICAS DE DESEMPEÑO

La evaluación del rendimiento del modelo se medirá tanto en el ámbito algorítmico como en su utilidad práctica en una situación de emergencia.

A. Métricas de Machine Learning (Técnicas)

- **F1-Score (Macro / Clase 1):** Al existir un desbalance moderado, el F1-Score será la métrica principal de optimización de la competencia, ya que balancea la precisión (no dar falsas alarmas) y la exhaustividad (no ignorar desastres reales).
- **Exactitud (Accuracy):** Como métrica secundaria para observar el porcentaje global de predicciones correctas del sistema.
- **Entropía Cruzada Binaria (Binary Cross-Entropy):** Función de pérdida que se monitoreará en las curvas de aprendizaje para verificar que las capas recurrentes no sufran de sobreajuste (*overfitting*) durante el entrenamiento.

B. Métricas de Negocio (Aplicación)

- **Falsos Negativos (Tasa de Omisión):** Minimizar los casos donde ocurre un desastre real pero el modelo lo clasifica como 0. En el contexto de emergencias, un falso negativo significa una solicitud de auxilio o reporte crítico ignorado, lo que puede costar vidas.
- **Latencia de Procesamiento:** Tiempo medido en milisegundos para clasificar un tuit individual. Las herramientas de escucha social de emergencia requieren procesar flujos de datos (*streams*) masivos en tiempo real; el modelo debe ser computacionalmente ligero.

V. REFERENCIAS Y RESULTADOS PREVIOS

Al ser una de las competencias más populares de Kaggle, existen múltiples arquitecturas de referencia documentadas que sirven como *baselines*:

- **1. Modelos Tradicionales (TF-IDF + Ridge / Naive Bayes):** Establecen la línea base inicial logrando una puntuación F1 de entre 0.75 y 0.78. Fallan frecuentemente detectando el sarcasmo o el uso metafórico de las palabras.
- **2. Modelos de Secuencia (LSTM/GRU Bidireccionales):** Al procesar el texto secuencialmente en ambas direcciones, logran capturar el contexto de la frase de mejor manera. Estructuras con capas Bidireccional(LSTM) o GRU junto con vectores de palabras preentrenados (como GloVe o FastText) elevan el F1-Score a rangos de 0.79 a 0.81.
- **3. Modelos basados en Transformers (BERT / Distil-BERT):** El estado del arte en la plataforma. Mediante el mecanismo de atención, entienden perfectamente la semántica del tuit, alcanzando puntuaciones F1 de 0.83 a 0.85, marcando la meta óptima de rendimiento.

REFERENCES

- [1] A. Howard, devrishi, P. Culliton, and Y. Guo, "Natural language processing with disaster tweets," <https://www.kaggle.com/competitions/nlp-getting-started>, 2019, kaggle.